

Avaliação Comparativa de Métodos de Explicabilidade em Múltiplos Domínios de Reconhecimento Visual

Gabriel Araujo Streicher
UFSCar
Sorocaba, SP

`gabriel.streicher@estudante.ufscar.br`

Juan Pedro
UFSCar
Sorocaba, SP

`juanp@estudante.ufscar.br`

Pedro Andrade Dorighello
UFSCar
Sorocaba, SP

`pedro.dorighello@estudante.ufscar.br`

Resumo

Este projeto avalia diferentes métodos de Inteligência Artificial Explicável de maneira quantitativa e qualitativa. O objetivo é investigar o comportamento e desempenho dos métodos Grad-CAM, Score-CAM, RISE e Integrated Gradients em diversos domínios de conjunto de dados. O trabalho também explora o impacto da inserção de um módulo de atenção na arquitetura utilizada e propõe abordagens híbridas realizando a fusão entre métodos.

1. Introdução

Com a crescente complexidade dos modelos de aprendizado profundo, a interpretabilidade é essencial para aumentar a confiança e a transparência em aplicações críticas, como diagnóstico médicos, ou simplesmente para tentar compreender esses modelos de caixa-preta, como as redes neurais profundas. Por esse motivo, explicabilidade de IA é uma área que cresceu muito nos últimos anos produzindo uma grande variedade de algoritmos capazes de gerar mapas de atenção para imagens de entrada. O problema que será investigado nesse trabalho é a avaliação e comparação desses diferentes métodos de explicabilidade que geram mapas de atenção em modelos de reconhecimento visual. Essa pesquisa visa comparar o desempenho de cada método de forma sistemática em múltiplos domínios com o objetivo de compreender o comportamento do algoritmo em cada situação e identificar qual o método mais adequado para cada tipo de imagem que será utilizado.

Código e modelos disponíveis em: <https://github.com/AraujoStreicher/explainability-benchmark>

Os métodos que serão abordados são: Grad-CAM[9], Score-CAM[10], Integrated Gradients[12] e RISE[11]. O Grad-CAM e o Integrated Gradients são abordagens baseadas em gradientes, o que significa que utilizam a retropropagação para o cálculo da sensibilidade de cada parte da imagem. Em contrapartida, o RISE e o Score-CAM são métodos livre de gradientes: o RISE opera através de perturbações na imagem de entrada e o Score-CAM pondera mapas de ativação com base na pontuação de confiança da rede no passo para frente.

Além disso, também será analisado o comportamento ao incluir um módulo de atenção na rede e explorada a combinação de métodos para avaliar se a fusão de suas saídas resulta em um desempenho superior.

Os resultados revelam que não há um método universal, evidenciando trade-offs claros entre fidelidade e robustez. Contudo, demonstra-se que a atenção explícita do CBAM e a proposta de uma abordagem Híbrida superam limitações individuais, oferecendo explicações mais equilibradas e precisas.

2. Trabalhos Relacionados

No contexto de aplicações em domínios específicos, Feitosa et al. [1] investigaram a explicabilidade em modelos de segmentação de imagens de peixes Pacu, avaliando métodos como Grad-CAM, *Saliency Maps* e *CNN Filters*. A metodologia de avaliação adotada pelos autores alinha-se diretamente com as métricas de fidelidade e robustez exploradas nesta pesquisa: eles utilizaram técnicas de perturbação de pixels (*white*, *dark* e *random noise*) nas regiões de maior relevância apontadas pelos mapas de calor para verificar se a performance do modelo era impactada, uma premissa análoga ao Teste de Deleção aqui implementado.

Uma contribuição chave desse trabalho foi a demonstração de que a combinação de métodos de XAI pode superar o desempenho das técnicas isoladas, gerando explicações mais completas e precisas. Esse resultado corrobora a investigação conduzida neste relatório sobre a eficácia de abordagens híbridas, reforçando a hipótese de que a integração de diferentes mecanismos de atribuição pode compensar limitações individuais, como o ruído excessivo ou a falta de detalhes finos.

3. Dados

O presente estudo insere-se em um esforço de pesquisa mais amplo que visa avaliar métodos de explicabilidade em múltiplos domínios visuais. Para garantir uma análise abrangente da generalização dos algoritmos de XAI, o projeto selecionou quatro conjuntos de dados públicos e amplamente utilizados, cada um representando um desafio particular de visão computacional:

CUB-200-2011 [2]: Focado na classificação de nível fino de espécies de pássaros, exigindo a distinção de detalhes sutis entre classes visualmente similares.

FER2013 [4]: Direcionado ao reconhecimento de expressões faciais, um domínio caracterizado por deformações não-rígidas e dependência de características localizadas, adotando-se as anotações refinadas do FER+ [3] para mitigar o alto nível de ruído nos rótulos da versão original.

NIH Chest X-Ray [5]: Aplicado à detecção de anomalias em imagens médicas, representando um cenário de alta relevância social onde a interpretabilidade é crítica para o diagnóstico.

Tiny-ImageNet [6]: Utilizado para a classificação genérica de objetos, servindo como uma base de comparação com maior diversidade de classes e variabilidade intra-classe.

4. Métodos

O problema foi abordado utilizando a rede neural convolucional ResNet-50 [13] pré-treinada no conjunto de dados ImageNet. Este modelo foi treinado para cada um dos conjuntos de dados descritos anteriormente e em cada um deles foram realizadas séries de avaliações para conseguir compreender o comportamento de cada método no domínio do conjunto.

Posteriormente, também foi avaliado se a implementação de um módulo de atenção na rede ajudaria na interpretabilidade. O módulo utilizado foi o CBAM e tem como objetivo fazer com que a rede aprenda a enfatizar características importantes e suprima as irrelevantes.

Além disso também será avaliado se a junção de dois métodos de explicabilidade melhora o desempenho apresentado. Para isso, será realizada a soma de dois mapas de calor e depois normalizado o resultado. Dessa forma, os

pixels considerados de alta importância por ambos os métodos terá uma ênfase maior da explicação.

4.1. Fidelidade

A fidelidade avalia quão importante realmente são as regiões destacadas no mapa de calor para a tomada de decisão do modelo. Para a avaliação é utilizado o algoritmo *deletion test*: geramos um *heatmap*, "deletamos" os pixels considerados mais importantes pelo mapa de calor e medimos novamente a confiança iterativamente até o modelo "quebrar" e não prever a imagem corretamente.

Se um método de explicabilidade estiver apontando corretamente as posições mais importantes da imagem, a quantidade de iterações necessárias para o modelo errar a predição deve ser baixa.

4.2. Robustez

A robustez avalia a estabilidade da explicação: pequenas e insignificantes mudanças na imagem de entrada não devem mudar drasticamente a explicação. Para isso, pegamos uma imagem e geramos seu *heatmap* original, em seguida adicionamos um ruído gaussiano na imagem e geramos novamente um novo *heatmap*. Por fim, comparamos ambos os mapas de calor com uma métrica de similaridade. Se uma explicação for robusta, o valor da similaridade deve ser próximo de 1.0.

4.3. Esparsidade e Coerência Espacial

Aqui avaliamos se a explicação está bem focada em poucas regiões da imagem e de forma bem agrupadas. Para a esparsidade, utilizamos o Índice Gini, um valor próximo de 1.0 significa alta esparsidade. Para a coerência espacial, os pixels de atenção são separados em clusters e espera-se que a maior quantidade de pixels esteja concentrada em apenas um cluster. Novamente, um valor próximo de 1.0 significa alta coerência espacial.

4.4. Consistência Intra-Classe

Um método de explicação é "consistente" se ele produz explicações similares para entradas similares. Para calcular a consistência, pegamos várias imagens diferentes que pertencem à mesma classe e comparamos os *heatmaps* gerados utilizando a Correlação de Pearson.

5. Experimentos

5.1. FER2013

5.1.1 Análise Quantitativa

A avaliação quantitativa revelou *trade-offs* distintos entre os métodos baseados em gradiente e os métodos livres de gradiente.

Robustez e Estabilidade: O método Score-CAM demonstrou superioridade notável em termos de robustez e consistência (Tabela 1), superando largamente as abordagens baseadas em gradiente. Isso sugere que, por utilizar o *forward pass* e pesos globais de canais, o Score-CAM é menos sensível a ruídos adversariais imperceptíveis que afetam drasticamente os gradientes locais utilizados pelo Grad-CAM e IG. O método RISE, por depender de amostragem aleatória, apresentou a pior consistência, tornando-o pouco confiável para diagnósticos precisos.

Fidelidade e Foco: Conforme evidenciado pelo Teste de Deleção (Figura 1), o Integrated Gradients demonstrou a maior fidelidade de forma consistente nas classes de melhor performance do modelo. Sua curva de decaimento de confiança foi a mais acentuada, provando que ele identifica com mais precisão os pixels críticos para a decisão. Em contraste, os métodos Grad-CAM e RISE apresentaram baixa fidelidade, com suas curvas de deleção permanecendo planas, indicando que os pixels destacados por eles não eram cruciais para o modelo. Em termos de esparsidade, o Grad-CAM e o IG geraram os mapas mais focados (Tabela 1), enquanto o Score-CAM tendeu a cobrir áreas faciais mais amplas.

Tabela 1. Resultados quantitativos dos métodos de XAI.

Método	Robustez	Consistência	Esparsidade	Coerência
<i>Classe: Raiva (Anger)</i>				
Grad-CAM	0.940	0.534	0.617	1.000
RISE	0.911	0.211	0.161	1.000
Score-CAM	0.996	0.882	0.516	1.000
Integrated Grad	0.613	0.214	0.588	0.239




Figura 1. Teste de Deleção de Fidelidade para a classe “Raiva”. **Nota:** O eixo X está invertido. Métodos que provocam uma queda abrupta na confiança do modelo (linhas descendentes) indicam maior fidelidade, pois a remoção de seus pixels mais importantes impacta drasticamente a predição.

5.1.2 Análise Qualitativa Visual




Figura 2. Comparação qualitativa dos métodos de XAI em uma amostra da classe “Raiva”.

A inspeção visual dos mapas de calor corrobora as métricas quantitativas e expõe as características intrínsecas de cada algoritmo:

- **Grad-CAM:** Produz mapas suaves e de baixa resolução, explicando sua alta pontuação em coerência espacial. No entanto, essa suavidade excessiva o impede de capturar os detalhes finos que o modelo realmente utiliza, resultando em sua baixa fidelidade na maioria das classes.
- **Integrated Gradients:** Apresenta um mapa de calor granulado, o que explica sua baixa pontuação em coerência espacial. No entanto, este “ruído” visual é, na verdade, uma atribuição precisa em nível de pixel, destacando contornos finos de olhos e boca. Isso explica por que o IG alcançou a maior fidelidade no Teste de Deleção, pois o modelo parece basear suas decisões nesses detalhes sutis.
- **Score-CAM:** Gera um heatmap consistentemente focado no centro do rosto. Isso explica tanto sua alta robustez quanto sua alta coerência. No entanto, essa análise qualitativa revela que o método sofre de um viés de centralidade, falhando em discriminar características específicas dentro da região central, o que justifica sua baixa fidelidade.
- **RISE:** Produz mapas dispersos e muitas vezes incoerentes, falhando em focar nas características faciais principais, o que explica seu baixo desempenho nas métricas de fidelidade.

Em suma, a análise do modelo ResNet-50 padrão revelou um trade-off acentuado entre as diferentes famílias de métodos XAI. O Integrated Gradients provou ser o único com alta fidelidade, indicando que o modelo baseava suas decisões em características sutis e de nível de pixel. Em contrapartida, os métodos de perturbação como Score-CAM, embora tenham demonstrado alta robustez, falharam nos testes de fidelidade, atuando mais como uma ferramenta de diagnóstico que expôs o “viés de centralidade” do modelo do que como um método de explicação confiável.

5.1.3 Impacto do Módulo CBAM e Abordagem Híbrida

A inclusão do módulo de atenção CBAM e a aplicação de uma estratégia de fine-tuning completo alteraram fun-




Figura 3. Comparação visual dos mapas de saliência para a classe “Felicidade”.

Tabela 2. Resultados quantitativos dos métodos de XAI.

Método	Robustez	Deleção	Esparsidade	Coerência
<i>Classe: Felicidade (Happiness)</i>				
CBAM Attention	0.002	0.499	0.461	0.007
Grad-CAM	0.003	0.190	0.678	0.008
Integrated Grad	0.003	0.247	0.564	0.038
RISE	0.010	0.411	0.173	0.035
Score-CAM	0.003	0.176	0.648	0.008
*Híbrido	0.004	0.193	0.663	0.042

*Método Híbrido: Grad-CAM X IG

damentalmente o comportamento do modelo e, consequentemente, o desempenho dos métodos de explicabilidade. O modelo com CBAM não apenas alcançou uma precisão superior de 82%, mas também demonstrou um raciocínio mais focado. A análise quantitativa, resumizada na Tabela 2, e a inspeção visual da Figura 3 revelam três mudanças de comportamento principais.

Primeiramente, houve uma inversão na hierarquia de fidelidade. Enquanto no modelo base o Integrated Gradients era o método superior e os métodos baseados em ativação eram ineficazes, no modelo com CBAM esta hierarquia se inverteu. O Grad-CAM (0.190) e o Score-CAM (0.176) tornaram-se os métodos com maior fidelidade no Teste de Deleção. Isso indica que a atenção explícita do CBAM criou mapas de características mais “legíveis” para esses métodos, alinhando suas explicações de forma mais precisa com a lógica de decisão do modelo.

Em segundo lugar, o modelo demonstrou uma sensibilidade a ruído drasticamente maior. O modelo com CBAM apresentou uma robustez drasticamente inferior em todos os métodos de explicação, com scores de correlação caindo para valores próximos de zero (Tabela 2). Isso sugere que o CBAM, ao aprimorar a precisão, pode ter tornado o modelo “frágil” e sensível a micro-texturas, fazendo com que pequenas perturbações alterassem fundamentalmente suas explicações, representando um claro trade-off entre acurácia e robustez da explicação.

Finalmente, diante deste novo comportamento, a fusão Híbrida (IG x Grad-CAM) emergiu como a solução mais equilibrada e completa. Conforme evidenciado na Tabela 2, esta abordagem alcançou uma fidelidade competitiva (0.193), manteve uma alta esparsidade (0.663) e obteve a maior pontuação de coerência espacial (0.042). Visualmente, como observado na Figura 3, a fusão atua como um

filtro semântico: o Grad-CAM delimita a região de interesse global, eliminando o ruído de fundo disperso do IG, enquanto o IG preserva os detalhes de alta frequência (como os cantos do sorriso destacados na Figura 3) que são invisíveis ao Grad-CAM. O resultado é um heatmap que é ao mesmo tempo focado, detalhado e o mais coeso visualmente.

Em suma, a integração do CBAM, embora tenha aumentado a sensibilidade do modelo a ruído, resultou em explicações universalmente mais fiéis. A atenção explícita forçou o modelo a depender de características semânticas mais fortes, e nesse cenário, a abordagem Híbrida se consolidou como o método mais eficaz para combinar a interpretabilidade regional com a precisão em nível de pixel, permitindo uma visualização transparente de que o modelo aprendeu a priorizar componentes faciais específicos.

5.2. CUB-200-2011

5.2.1 Análise Quantitativa

A análise do conjunto de dados será focada na classe *Ivory Gull*: uma ave marinha de plumagem totalmente branca, nativa do Ártico, conhecida por sua beleza e raridade. A Tabela 3 mostra que o método RISE apresentou os melhores resultados nas categorias robustez, consistência e coerência. Entretanto, os métodos Grad-CAM e Score-CAM conseguiram apresentar resultados bem próximos.

Todos os métodos apresentaram um valor baixo na categoria consistência, contudo isso é algo esperado nesse conjunto de dados pois as imagens dos pássaros podem se apresentar em posições e ângulos diferentes. Dessa forma, gerando *heatmaps* completamente diferentes dentro de uma mesma classe.

Tabela 3. Resultados quantitativos do CUB-200-2011.

Método	Robustez	Consistência	Esparsidade	Coerência
<i>Classe: Ivory Gull</i>				
Grad-CAM	0.986	0.318	0.227	0.966
RISE	0.990	0.441	0.014	0.983
Score-CAM	0.983	0.238	0.831	0.947
Integrated Gradients	0.088	0.227	0.806	0.147

Quanto a fidelidade, a Tabela 4 mostra a quantidade média de pixels removidos da imagem de entrada até que a predição do modelo falhasse. É interessante notar que, apesar de valores baixos nas categorias discutidas acima, o método Integrated Gradients foi o melhor em definir os pontos vitais para a predição da imagem. Enquanto isso, o método RISE foi o pior nesta categoria. Podemos concluir que, apesar do método apresentar robustez e consistente, este não consegue explicar corretamente a predição.

Tabela 4. Fidelidade do CUB-200-2011.

Método	Pixels removidos	Porcentagem da imagem
<i>Classe: Ivory Gull</i>		
Integrated Gradients	25750	12%
Score-CAM	35250	17%
Grad-CAM	68450	34%
RISE	104150	51%

5.2.2 Análise Qualitativa Visual

Na Figura 4 é possível visualizar uma amostra dos mapas de calor gerados e torna-se claro a razão dos resultados obtidos e discutidos anteriormente.




Figura 4. Comparação dos resultados no CUB-200-2011

- **Grad-CAM:** Apresenta uma ativação esférica e suave sobre o pescoço do pássaro, o que explica a pontuação alta na categoria coerência espacial.
- **Integrated Gradients:** Em oposição ao Grad-CAM, o método apresenta vários pontos dispersos, onde vários pixels brilham ao longo de todo o corpo do pássaro.
- **RISE:** Apesar de apresentar um comportamento parecido com o Grad-CAM, é notável um fundo ruidoso (azul claro), falhando em focar nas características principais.
- **Score-CAM:** O Score-CAM obteve um mapa que foca inteiramente no corpo do pássaro e não apenas em uma região ou característica específica.

A partir dessa análise, o método que apresentou-se mais adequado foi o Score-CAM que, apesar de ter obtido o melhor valor apenas na categoria esparsidade, foi consistente ao longo de toda a análise quantitativa e qualitativa.

5.2.3 Impacto do Módulo CBAM e Abordagem Híbrida

Ao analisar a Tabela 5, a introdução do módulo de atenção CBAM não trouxe mudanças muito significativas no resultado. Nota-se que o CBAM favoreceu a métrica de coerência nos métodos baseados em gradiente. O destaque principal é o método IG que apresentou um salto de 0.147 para 0.644. Além disso, o método Grad-CAM apresentou uma coerência perfeita: 1.000.

Entretanto, houve também quedas no valor de esparsidade: 0.806 para 0.295 no IG. Além de uma queda de 0.831 para 0.531 no método Score-CAM. Quanto a fidelidade, é

notável uma piora muito considerável do método Integrated Gradients.

Tabela 5. Resultados quantitativos do CUB-200-2011 com CBAM.

Método	Robustez	Consistência	Esparsidade	Coerência
<i>Classe: Ivory Gull</i>				
Grad-CAM	0.983	0.313	0.257	1.000
RISE	0.992	0.196	0.012	0.767
Score-CAM	0.896	0.198	0.531	0.997
Integrated Gradients	0.102	0.198	0.295	0.644
GradCAM+IG	0.819	0.324	0.581	0.522

Finalmente, a fusão entre os métodos GradCAM e IG se mostrou a mais competente em gerar as explicações. Esta apresentou os maiores valores para as métricas consistência e esparsidade. Além de apresentar um valor alto para robustez (0.819) e equilibrar os valores de esparsidade e coerência espacial. Também é notável que a fusão apresentou uma fidelidade melhor do que ambos os métodos individualmente.

Tabela 6. Fidelidade do CUB-200-2011 com CBAM.

Método	Pixels removidos	Porcentagem da imagem
<i>Classe: Ivory Gull</i>		
Score-CAM	8900	4%
Grad-CAM+IG	15550	7%
Grad-CAM	16800	8%
Integrated Gradients	20300	10%
RISE	22450	11%




Figura 5. Mapas de atenção com CBAM

5.3. Tiny ImageNet

5.3.1 Avaliação Qualitativa

A Figura 6 apresenta os *heatmaps* para uma imagem da classe *Goldfish* (*Carassius auratus*).

- **Grad-CAM e Score-CAM:** Ambos produziram mapas contínuos e suaves, focando na região central do objeto. O Grad-CAM tende a uma explicação visualmente mais "limpa", cobrindo uma área maior do peixe.
- **RISE:** O método gera um mapa mais disperso e granulado, cobrindo partes que percorrem o contorno do peixe (parte que delimita o objeto da área externa).

- **Integrated Gradients (IG):** O IG destaca características de alta frequência, delineando bordas e texturas específicas (como escamas e barbatanas). O mapa resultante é visualmente ruidoso, refletindo a sensibilidade do método a pixels individuais.




Figura 6. Comparação dos resultados no Tiny ImageNet (Classe: Goldfish)

5.3.2 Análise Quantitativa

A Tabela 7 resume as métricas médias calculadas sobre um subconjunto representativo de imagens da classe *Goldfish*.

Tabela 7. Métricas de avaliação (Classe Goldfish)

Método	Fidelidade	Robustez	Esparsidade	Coerência	Consistência
Grad-CAM	>56*	0.9707	0.6571	1.0000	0.5932
Score-CAM	>57*	0.9765	0.6062	0.9921	0.6806
RISE	45	0.9677	0.3931	0.8230	0.4912
IG	16	0.3829	0.5129	0.1651	0.1366

Fidelidade (Deletion Test): O Integrated Gradients demonstrou a maior fidelidade local, com um passo médio de quebra de apenas 16. Isso indica que os pixels específicos destacados pelo IG (bordas, texturas) são cruciais para a decisão do modelo. O RISE também teve bom desempenho (quebra no passo 45). Em contraste, Grad-CAM e Score-CAM apresentaram menor fidelidade neste teste: o modelo precisou de uma quantidade consideravelmente maior de pixels removidos para quebrar, e em alguns casos, a remoção das áreas indicadas por eles não foi suficiente para alterar a predição do modelo, com a confiança oscilando sem cair drasticamente. Isso sugere que esses métodos focam em características contextuais ou correlacionadas mais amplas, que, embora visualmente coerentes, não são as únicas responsáveis pela classificação.

Robustez e Consistência: Os métodos baseados em ativação (Grad-CAM, Score-CAM) e perturbação (RISE) foram extremamente robustos (> 0.96) a ruídos na entrada. O Score-CAM destacou-se com a maior consistência intra-classe (0.68), indicando que ele gera explicações muito similares para diferentes imagens da mesma classe (*Goldfish*). O IG teve desempenho fraco nestes quesitos (robustez 0.38, consistência 0.13), confirmando sua alta sensibilidade a pequenas variações na entrada.

Interpretabilidade (Coerência Espacial): Grad-CAM e Score-CAM obtiveram coerência espacial quase perfeita

(≈ 1.0), refletindo mapas de calor contínuos e suaves, ideais para inspeção humana rápida. O IG apresentou a menor coerência (0.16), resultado de seu mapa fragmentado e ruidoso.

5.3.3 Impacto do Módulo CBAM e Abordagem Híbrida

Com a incorporação do módulo CBAM no modelo ResNet-50, novos experimentos foram conduzidos utilizando uma abordagem Híbrida (fusão de Score-CAM e Integrated Gradients). Para esta análise, utilizou-se a classe *Salamandra* para ilustrar o impacto na granularidade das explicações. A seleção do Score-CAM e do Integrated Gradients (IG) para compor a abordagem de fusão híbrida fundamentou-se na natureza estritamente complementar de suas características observadas nos experimentos individuais. Enquanto o IG destacou-se pela alta fidelidade local, capturando detalhes de alta frequência e texturas essenciais — embora prejudicado por ruído disperso em toda a imagem —, o Score-CAM demonstrou superioridade na delimitação semântica da região de interesse, oferecendo a maior coerência espacial e robustez entre os métodos avaliados. Desta forma, a estratégia de fusão propõe utilizar a estabilidade do mapa do Score-CAM como um filtro de atenção espacial para suprimir o ruído de fundo inerente ao IG, preservando apenas os gradientes de alta precisão que residem dentro da área relevante do objeto.

A Tabela 8 apresenta o comparativo entre os métodos aplicados ao modelo com CBAM e a abordagem híbrida. Nota-se que o mapa de atenção intrínseco do CBAM (*CBAM Attention*) serve como uma âncora de estabilidade para a rede, apresentando alta robustez (0.8733) e consistência (0.7984), atuando como um guia espacial confiável.

Tabela 8. Avaliação quantitativa no modelo com CBAM (Classe Salamandra).

Método	Fidelidade	Robustez	Esparsidade	Coerência	Consistência
CBAM Attention	23	0.8733	0.1550	0.9866	0.7984
IG	1	0.4108	0.5785	0.0282	0.1180
Score-CAM	4	0.9441	0.5704	1.0000	0.7997
Híbrido	1	0.6175	0.7870	0.0707	0.3310

5.3.4 Análise da Fusão Híbrida:

- **Fidelidade Máxima:** A abordagem Híbrida manteve a fidelidade extrema do IG, quebrando a confiança do modelo logo no **passo 1** do teste de deleção. Isso confirma que a fusão preserva os pixels críticos para a decisão.
- **Esparsidade (Foco):** O método Híbrido obteve o maior Índice de Gini (**0.7870**), superando tanto o IG quanto o Score-CAM isolados. Isso quantifica o efeito de "limpeza visual": a fusão elimina o ruído de fundo do IG (que pos-

sui gradientes dispersos por toda a imagem) e restringe a explicação à área de foco delimitada pelo Score-CAM.

- **Equilíbrio de Robustez:** Ao multiplicar os mapas, a abordagem híbrida conseguiu elevar a robustez do IG de 0.41 para **0.6175**, e a consistência de 0.11 para **0.33**. Embora ainda inferior ao Score-CAM puro, esse ganho torna a explicação detalhada do IG mais confiável e menos suscetível a variações aleatórias.

Visualmente (Figura 7), observa-se que enquanto o IG puro apresenta granulação dispersa por toda a imagem e o Score-CAM foca em uma área ampla sobre a salamandra, o método Híbrido concentra os detalhes de alta frequência (grãos) estritamente dentro da região de interesse, facilitando a interpretação humana sem perder a precisão do pixel.




Figura 7. Impacto do CBAM e Fusão Híbrida na classe Salamandra. O método Híbrido (d) combina o foco espacial do Score-CAM (c) com os detalhes do IG (b), resultando em uma explicação precisa e limpa.

5.4. NIH Chest X-Ray

5.4.1 Análise Quantitativa

Este conjunto de dados é um problema *multi-label* e a análise será focada no resultado “*Infiltration*” estar presente na predição. A complexidade deste dataset é altíssima e poucas mudanças na imagem podem fazer grande diferença no valor do resultado. Nestas análises, o método RISE apresentou a maior robustez (0.974). No entanto, ele teve a pior esparsidade (0.058), indicando que gera mapas muito espalhados e pouco focados.

O Score-CAM liderou em consistência (0.682) e alcançou coerência perfeita (1.000). Dessa forma, se mostrou um ótimo método apesar da baixa pontuação na robustez. Esse baixo valor pode ser compreendido por estar sendo tratado um domínio de imagens que cada detalhe importa para a tomada de decisão do modelo. Sendo assim, alguns ruídos na imagem de raio-x podem causar alterações no resultado facilmente.

Nessas métricas, o método IG teve um desempenho muito abaixo do restante. Isso indicaria um método fraco para esse domínio e a métrica de fidelidade comprova que este não foi capaz de apresentar uma boa explicação da imagem.

A Tabela 10 mostra que o método RISE foi o melhor em definir os pontos vitais para a predição da imagem. Além

Tabela 9. Resultados quantitativos do NIH Chest X-Ray.

Método	Robustez	Consistência	Esparsidade	Coerência
Classe: <i>Infiltration</i>				
Grad-CAM	0.018	0.472	0.688	1.000
RISE	0.974	0.319	0.058	0.850
Score-CAM	0.026	0.682	0.618	1.000
Integrated Gradients	0.010	0.135	0.556	0.521

disso, o método Score-CAM, apesar de apresentar bons valores anteriormente, ficou em último lugar nesta pontuação.

Tabela 10. Fidelidade do NIH Chest X-Ray.

Método	Pixels removidos	Porcentagem da imagem
Classe: <i>Infiltration</i>		
RISE	1285	2%
Grad-CAM	1772.5	3%
Integrated Gradients	4170	8%
Score-CAM	6030	12%

5.4.2 Análise Qualitativa Visual

Na Figura 8 é possível visualizar uma amostra dos mapas de calor gerados.

- **Grad-CAM e Score-CAM:** Ambos os métodos mostram mapas de calor suaves e conexos focados na região do pulmão. Entretanto o Grad-CAM está um pouco mais deslocada para a esquerda.
- **Integrated Gradients:** Apresentou importância em locais bem parecidos do Grad-CAM mas é visível alguns pixels considerados importantes ao redor do corpo da pessoa.
- **RISE:** Comprova que o mapa de atenção gerado pelo método é muito espalhado. Apresenta manchas que cobrem grandes áreas e muita dúvida sobre qual a área mais importante da imagem. Entretanto, por conta do bom resultado na fidelidade, a região mais destacada em vermelho deve ser realmente o ponto mais importante da imagem para a tomada de decisão.




Figura 8. Comparação dos resultados no NIH Chest X-Ray

5.4.3 Impacto do Módulo CBAM e Abordagem Híbrida

A introdução do módulo de atenção trouxe maior estabilidade aos métodos. O maior impacto notável do CBAM foi

na robustez e na consistência. Para o Grad-CAM, a robustez saltou de 0.018 para 0.271. Enquanto isso, para o Score-CAM houve um salto enorme de 0.026 para 0.764, ficando atrás apenas do RISE (0.875).

A métrica consistência melhorou em todos os métodos com a inserção do CBAM. No Score-CAM foi possível atingir uma pontuação igual a 0.922 e no Grad-CAM uma pontuação de 0.839, valores excelentes para a categoria.

É interessante notar que os métodos melhoraram mesmo com o CBAM não conseguindo gerar um mapa de atenção espacial muito adequado. Um exemplo disso pode ser notado na Figura 9.

Tabela 11. Resultados quantitativos do NIH Chest X-Ray com CBAM.

Método	Robustez	Consistência	Esparsidade	Coerência
<i>Classe: Infiltration</i>				
Grad-CAM	0.271	0.839	0.715	1.000
RISE	0.875	0.434	0.030	0.836
Score-CAM	0.764	0.922	0.392	1.000
Integrated Gradients	0.030	0.235	0.578	0.263
Grad-CAM + Score-CAM	0.554	0.892	0.485	1.000

A partir dos resultados obtidos foi decidido realizar a fusão entre os métodos Grad-CAM e Score-CAM. O objetivo é conseguir uma explicação que mantenha o alto valor de consistência e coerência espacial, além de equilibrar a robustez e esparsidade. Os resultados conseguiram ser atingidos com sucesso: manteve a coerência perfeita 1.000 de ambos os métodos, obteve uma consistência muito alta e uma robustez intermediária. Dessa forma, obtivemos resultados muito próximos do melhor método que foi o Grad-CAM mas preservando a robustez do Score-CAM.

Tabela 12. Fidelidade do NIH Chest X-Ray com CBAM.

Método	Pixels removidos	Porcentagem da imagem
<i>Classe: Infiltration</i>		
Grad-CAM	173.75	0.3%
Grad-CAM+Score-CAM	197.50	0.3%
RISE	305	0.6%
Score-CAM	342.50	0.6%
Integrated Gradients	405	0.8%




Figura 9. Mapas de atenção com CBAM

6. Conclusão

No contexto do *dataset* FER2013, caracterizado por imagens irregulares com variações de luz, poses e oclusões, a análise inicial revelou um modelo apoiado por características a nível de pixel e vieses de centralidade, expostos pelo IG e Score-CAM. Com a integração do CBAM, os métodos de explicabilidade tiveram uma melhora na fidelidade, em troca de menor robustez a ruídos. Diante disso, o método híbrido se mostrou como a melhor solução, unindo a precisão granular do IG à coerência espacial do Grad-CAM, para identificar as sutilezas das expressões faciais.

O conjunto de dados CUB-200-2011 é um domínio que cada imagem de uma mesma classe pode ser apresentada de formas diferentes, exigindo a distinção de detalhes sutis entre classes visualmente similares. Neste domínio, o método Score-CAM apresentou-se como uma ótima opção: apresentou uma alta robustez, esparsidade, coerência espacial e foi muito bem na fidelidade. Além de tudo isso, conseguiu gerar um mapa bem explicativo visualmente. Entretanto, esse método foi prejudicado pela inserção do módulo CBAM.

Ainda no *dataset* CUB, a abordagem híbrida se mostrou mais uma vez uma escolha interessante. Esta conseguiu a melhor consistência e esparsidade. Além de atingir uma fidelidade superior a cada um dos métodos individuais utilizados.

No conjunto de dados Tiny ImageNet, as imagens (que são de baixa resolução e foram redimensionadas para a entrada da rede) apresentam frequentemente o objeto de interesse ocupando uma porção majoritária do quadro. Essa característica topológica favorece naturalmente métodos como o Score-CAM e o Grad-CAM, que tendem a destacar grandes massas centrais. Em contrapartida, a baixa resolução nativa impõe um desafio adicional aos métodos de sensibilidade pixel-a-pixel, como o Integrated Gradients: a falta de nitidez nos detalhes e o desfoque natural gerado pela ampliação da imagem contribuem para a dispersão ruidosa observada nos heatmaps, uma limitação técnica que foi efetivamente mitigada apenas através da filtragem espacial proporcionada pela abordagem híbrida proposta.

Quanto ao conjunto de dados NIH Chest X-Ray, este é um domínio complexo que poucas alterações na imagem podem mudar o resultado da predição. Por conta disso, é esperado uma baixa robustez dos métodos. Entretanto, o RISE apresentou-se como um bom método na análise quantitativa com uma robustez muito superior aos demais. Ao analisar o mapa de calor gerado, fica evidente que este teve bastante dúvida sobre as regiões mais importantes, gerando mapas muito dispersos. O Grad-CAM conseguiu gerar mapas mais consistentes e coerentes. Por isso, foi considerado o melhor neste domínio.

A inserção do CBAM na arquitetura gerou um aumento significativo na consistência intraclasse e a abordagem hí-

brida novamente se apresentou como uma ótima escolha.

Em suma, a análise comparativa entre múltiplos domínios demonstrou que a eficácia dos métodos de XAI é dependente das características de cada *dataset*, mesmo que métodos como o RISE tenham apresentado limitações consistentes em todos os cenários. Entretanto, a integração do módulo CBAM refinou a interpretabilidade dos métodos baseados em gradiente e ativação, elevando consideravelmente a fidelidade dos métodos. Neste contexto, a estratégia Híbrida consolidou-se como a solução mais robusta, superando as limitações individuais dos métodos isolados, tanto nas métricas quantitativas quanto na clareza visual.

Trabalhos futuros deverão investigar a generalização desta fusão para arquiteturas mais recentes, como *Vision Transformers*, e explorar mecanismos para automatizar a combinação de métodos de explicabilidade de acordo com a complexidade da imagem de entrada.

Referências

- [1] DA C. FEITOSA, J. et al. Enhancing explainability in pacu fish image segmentation using saliency maps and combined explainable AI methods. *Smart Agricultural Technology*, v. 12, p. 101286, 8 ago. 2025. 1
- [2] X, W. CUB-200-2011. Disponível em: <https://www.kaggle.com/datasets/wenewone/cub2002011>. 2
- [3] Microsoft. FERPlus. Disponível em: <https://github.com/Microsoft/FERPlus>. 2
- [4] SAMBARE, M. FER-2013. Disponível em: <https://www.kaggle.com/datasets/msambare/fer2013>. 2
- [5] NIH Chest X-rays. Disponível em: <https://www.kaggle.com/datasets/nih-chest-xrays/data>. 2
- [6] Tiny ImageNet. Disponível em: <https://www.kaggle.com/c/tiny-imagenet>. 2
- [7] ResNet-50 com CBAM. Disponível em: <https://github.com/Ugenteraan/ResNet-50-CBAM-PyTorch>
- [8] Implementação RISE no Pytorch. Disponível em: <https://github.com/eclique/RISE/blob/master/explanations.py>
- [9] SELVARAJU, Ramprasad R. et al. Grad-CAM: Visual explanations from deep networks via gradient-based localization. In: Proceedings of the IEEE International Conference on Computer Vision. 2017. 1
- [10] WANG, Haofan et al. Score-CAM: Score-weighted visual explanations for convolutional neural networks. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops. 2020. 1
- [11] PETSUK, Vitali; DAS, Abir; SAENKO, Kate. RISE: Randomized input sampling for explanation of black-box models. In: Proceedings of the British Machine Vision Conference (BMVC). 2018. 1
- [12] SUNDARARAJAN, Mukund; TALY, Ankur; YAN, Qiqi. Axiomatic attribution for deep networks. In: Proceedings of the 34th International Conference on Machine Learning. 2017. 1
- [13] He, K.; Zhang, X.; Ren, S.; Sun, J. Deep Residual Learning for Image Recognition. In: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016, p. 770–778. doi:10.1109/CVPR.2016.90. 2